PROYECTO ACADÉMICO · GRUPO 3 · PROJECT BREAK 2

MadridRumbo V2

Asistente conversacional multiagente para el transporte público de la Comunidad de Madrid

Rubén Jiménez Gutiérrez · Guzmán López Barceló · José Manuel Gil Ruiz

A · PRODUCTO

Moverse por Madrid obliga a consultar fuentes que no hablan entre sí

Información fragmentada

Tarifas, zonas y abonos repartidos en el BOCM, en preguntas frecuentes y en tablas de precios.

Cálculos a mano

Sumar billetes, cruzar zonas y títulos, y volver a empezar si cambia el trayecto.

Silos de datos

Horarios, rutas y precios viven en sitios distintos y nadie los junta.

Lo que la persona quiere saber es simple: ¿qué billete necesito y cómo llego?

NUESTRA SOLUCIÓN

Orquestación Multiagente Controlada

Respuestas ancladas a evidencia documental.

A · PRODUCTO

Un asistente que decide cómo responder y no inventa

1. **Normativa y tarifas**
   Responde con evidencia de documentos oficiales del CRTM.

2. **Rutas con zona y precio**
   Planifica el trayecto, calcula zona y precio, y pide tu aprobación.

3. **Imágenes y cálculos**
   Lee los precios de un cartel y suma el total exacto.

4. **Sin evidencia, no responde**
   Si el dato no está en los documentos, lo dice.

Ejemplos reales

«¿Qué es la Tarjeta Azul y dónde es válida?»

«¿Cómo voy de la Puerta del Sol a Atocha?»

«Analiza assets/imagen_demo.jpg e indica los precios.»

«¿Cuál es la capital de Francia?» ⟶ no es de este dominio

A · PRODUCTO

Dominio: transporte público del CRTM, el mismo del primer proyecto

5

fuentes oficiales
BOCM, CRTM y paradas

+22.000

paradas agrupadas
en 3.748 bloques

3.971

chunks indexados
en ChromaDB

Corpus: tarifas y precios publicados en el BOCM, información de billetes y preguntas frecuentes del CRTM, y el listado de paradas. Embeddings con Gemini (3.072 dimensiones).

Por qué estos datos

- Oficiales y citables: las tarifas se cobran, no se pueden inventar.
- Reutiliza el RAG del primer proyecto, como recomienda el enunciado.
- Hay APIs abiertas para completarlo: Nominatim, Google Routes, EMT y Open-Meteo.

Encaje en el puzzle: RAG → Agente → MLOps

HECHO

RAG

Corpus CRTM, embeddings, ChromaDB y respuestas ancladas.

ESTA ENTREGA

Agente

Grafo LangGraph con supervisor, 5 especialistas, HITL, tools con allowlist y dos clientes.

SIGUIENTE

MLOps

Persistencia en disco, contenedor, integración continua y evaluación continua.

Demo: de la pregunta a un plan aprobado

1	`streamlit run app.py`	Pregunta de ruta: «¿Cómo puedo ir desde la Puerta del Sol hasta la Estación de Atocha?». Aparece el plan.
2	`Aclaraciones`	Si hay alguna ambigüedad, el sistema solicita aclaraciones.
3	`Aprobar`	«Conversación terminada»: solo el grafo decide el fin. Se ve el desplegable «Pasos seguidos».
4	`Imagen`	«Según assets/imagen_demo.jpg, ¿cuánto cuestan 1 billete sencillos EMT y 1 Exprés Aeropuerto?»

Plan B si falla la red o una API: modo simulado (MADRIDRUMBO_GRAFO=falso) y vídeo de respaldo.

Bajo el capó: Ingeniería y Aprendizaje

La ingeniería real detrás del producto

B · TÉCNICO (≈6 min, diapositivas 7 a 14)

Arquitectura LangGraph: un supervisor reparte y un humano aprueba las rutas



- Estado por thread_id (InMemorySaver)
- Límites y allowlist aplicados en Python
- Seis claves públicas: respuesta, plan, log, traza, hitl_pendiente y done

B · TÉCNICO

Cinco especialistas, cinco tools y una allowlist

Especialista	Tool	Qué hace
rag	rag_ask	Responde con evidencia del corpus; sin ella, se abstiene
horarios	hora_actual, rag_ask	Hora de Madrid y servicio de «hoy» y «ahora»
rutas	planificar_ruta	Nominatim + Google Routes; zona y precio desde el RAG; BiciMAD y clima
auxiliar	hora_actual, calculadora	Hora actual y cálculos exactos, sin eval
imagen	describir_imagen	Lee textos e importes de la imagen demo



Foto: BiciMAD, alternativa en bici cuando el trayecto es de 1 a 6 km y hace buen tiempo.

Las tools solo se ejecutan con ejecutar_tool(): comprueba la allowlist y deja traza (nombre, argumentos, estado y extracto).

B · TÉCNICO

RAG completo como tool: indexar, consultar con fuentes y abstenerse

1 · INDEXADO

```
python -m rag.rag_cli --index
```

4.054 chunks en ChromaDB. Reutiliza los embeddings si coinciden el modelo y el número de chunks.

2 · EN CORPUS

```
python -m rag.rag_cli --ask
"¿Qué es la Tarjeta Azul?"
```

Respuesta con los fragmentos recuperados y sus fuentes.

3 · FUERA DE CORPUS

```
python -m rag.rag_cli --ask
"¿Cuál es la capital de
Francia?"
```

«No lo sé, no está en los documentos.»

- Las tablas Markdown se conservan como chunks indivisibles.
- El prompt obliga a responder solo con el contexto recuperado (TOP_K = 4).

B · TÉCNICO

Multimodal: la tool de imagen lee los precios



Billetes de autobuses EMT

Lista de precios de billetes de autobuses urbanos de Madrid (EMT):

- **Billete sencillo EMT:** 1,50 €
- **Billete sencillo TransBus:** 1,80 €
- **Billete Exprés Aeropuerto:** 5,00 €
- **Metrobús 10 viajes:** 7,30 €

assets/imagen_demo.jpg · captura de «Billetes de autobuses EMT»

describir_imagen leyó: sencillo EMT 1,50 € · TransBus 1,80 € · Exprés Aeropuerto 5,00 € · Metrobús 7,30 €

TRAZA Y PASOS SEGUIDOS

```
Flujo: supervisor → tarifas →
auxiliar

Tools:
1. describir_imagen [ok] …


Cada tool: nombre, argumentos,
estado y extracto. El detalle
completo está en el panel
Depuración.
```

Metodología de Desarrollo

SPECIFICATION-DRIVEN

SDD

1. Especificaciones EARS

Definición rigurosa de especificaciones y requisitos funcionales.

2. Desarrollo TDD & Aislado

Tests primero, una tarea cada vez, ejecutados localmente sin llamadas externas a API.

3. Reglas y Gobernanza

Constitución del proyecto y especificación estricta en **`AGENTS.md`**.

WORKFLOW

Git & Versionado

Estrategia de Ramas:

`main` ← entrega estable

`develop` ← integración continua

`feature/*` ← fix, docs y nuevas tareas

Control de Calidad

Pull Requests obligatorios con revisión cruzada de colaboradores antes de fusionar a `develop`.

B · TÉCNICO

Tres fallos conocidos y los siguientes pasos

1

Precios con origen y destino

Al pedirle precios con origen y destino el supervisor enruta la consulta hacia el nodo rutas.

2

Rutas: Zona y precio

No siempre muestra la información de zona y precio al calcular una ruta.

3

Latencia y saturación de Gemini

Errores 503; una consulta de imagen llegó a tardar 161 s en una prueba.

Siguientes pasos (MLOps)

- Persistir el estado en disco (SqliteSaver)
- Contenedor y integración continua con los tests sin API
- Evaluar la recuperación de forma continua
- Medir latencia y tasa de errores del modelo
- Calendario de festivos en hora_actual

Gracias.

Un asistente que decide cómo responder, pide permiso antes de dar una ruta por buena y no inventa.

¿Preguntas o comentarios?

Fuentes de las imágenes

- assets/imagen_demo.jpg: captura propia de RedTransporte, precios de billetes y abonos (tarifas 2026), © RedTransporte, uso educativo. Fecha de captura: 14/10/2026.
- Foto de BiciMAD: www.esmadrid.com (bicimad_2023.jpeg).